INCIDÊNCIA E PREDIÇÃO DE DIABETES MELLITUS TIPO 2 NA POPULAÇÃO INDÍGENA NORTE-AMERICANA "PIMA"

Matheus Candido & Fernando Simão

RESUMO: O Diabetes Mellitus é uma doença crônica de elevada prevalência mundial, associada a complicações metabólicas e cardiovasculares. O objetivo deste estudo foi realizar análises estatísticas descritivas e inferenciais, além de desenvolver modelos preditivos para o diagnóstico de diabetes utilizando o software R. Utilizou-se um conjunto de dados contendo variáveis clínicas como glicose, índice de massa corporal (IMC), pressão arterial, idade e histórico gestacional. Inicialmente, realizou-se tratamento dos dados com substituição de valores ausentes por imputação via mediana estratificada pelo desfecho. Foram aplicadas estatísticas descritivas, matriz de correlação, testes de hipóteses (Qui-Quadrado, Teste F para variâncias e teste de comparação de proporções), regressão linear simples e regressão logística com divisão treino/teste (80/20). Os resultados indicaram associação significativa entre glicose categorizada e diagnóstico de diabetes ($p < 0,05$), bem como diferenças nas proporções de diabetes entre faixas etárias. A regressão linear evidenciou relação positiva entre IMC e glicose. O modelo de regressão logística apresentou desempenho satisfatório, com acurácia superior a 70%, indicando boa capacidade preditiva. Conclui-se que variáveis metabólicas, especialmente glicose e BMI, apresentam forte relação com o diagnóstico de diabetes, e que modelos estatísticos podem auxiliar na predição da doença.

Palavras-chave: Diabetes Mellitus; Estatística Inferencial; Regressão Logística; Testes de Hipóteses; Modelagem Preditiva.

INTRODUÇÃO

O Diabetes Mellitus é caracterizado por hiperglicemia persistente decorrente de defeitos na secreção ou na ação da insulina, configurando-se como um dos principais problemas de saúde pública mundial (SOCIEDADE BRASILEIRA DE DIABETES, 2023). A doença está associada a complicações micro e macrovasculares, elevando a morbimortalidade e os custos com saúde pública.

Estudos recentes demonstram que fatores como obesidade, idade avançada e histórico familiar estão fortemente associados ao desenvolvimento da doença (INTERNATIONAL DIABETES FEDERATION, 2021). O Índice de Massa Corporal (IMC) e os níveis de glicose plasmática são considerados importantes marcadores clínicos para diagnóstico e monitoramento (AMERICAN DIABETES ASSOCIATION, 2023).

A utilização de métodos estatísticos e técnicas de modelagem preditiva tem se mostrado eficaz na identificação de fatores de risco e na previsão do diagnóstico da doença (SILVA et al., 2022). Testes de hipóteses, análises de correlação e modelos de regressão são amplamente empregados para avaliar associações entre variáveis clínicas e o desfecho da doença.

Diante desse contexto, o objetivo geral deste trabalho foi realizar análises estatísticas descritivas e inferenciais, bem como desenvolver modelos de regressão linear e logística para avaliar fatores associados ao diagnóstico de diabetes utilizando o software R.

MATERIAL E MÉTODOS

O estudo utilizou um banco de dados secundário denominado diabetes.csv, contendo variáveis clínicas: número de gestações (Pregnancies), glicose (Glucose), pressão arterial (Blood Pressure), espessura da pele (Skin Thickness), insulina (Insulin), índice de massa corporal (BMI), função hereditária do diabetes (Diabetes Pedigree Function), idade (Age) e diagnóstico (Outcome).

Inicialmente, realizou-se limpeza dos dados, substituindo valores iguais a zero por NA nas variáveis fisiológicas (glicose, pressão arterial, espessura da pele, insulina e BMI), pois tais valores são biologicamente inconsistentes. Em seguida, aplicou-se imputação pela mediana estratificada pelo desfecho (diabéticos e não diabéticos).

Foram realizadas análises de estatística descritiva (média, desvio-padrão e gráficos exploratórios). A associação entre variáveis quantitativas foi avaliada por meio da matriz de correlação de Pearson.

Na inferência estatística foram aplicados:

Teste Qui-Quadrado de Independência (faixa etária vs. diabetes; glicose categorizada vs. diabetes);
Teste F para comparação de variâncias (glicose, IMC e idade entre grupos);
Teste de comparação de proporções entre faixas etárias e entre gêneros;
Regressão Linear simples (Glicose ~ BMI);
Regressão Logística com divisão treino/teste (80/20), normalização das variáveis e avaliação por matriz de confusão e acurácia.
O nível de significância adotado foi de 5% ($\alpha = 0,05$).

RESULTADOS E DISCUSSÃO

A análise da distribuição da variável glucose (Figura 1) revela um comportamento que se aproxima de uma distribuição normal, com a maior concentração de observações situadas entre 100 e 125 mg/dL. Nota-se, no entanto, uma leve assimetria à direita (cauda mais alongada para valores maiores), o

que reflete a presença de indivíduos com quadros de hiperglicemia, um indicativo clássico na triagem de

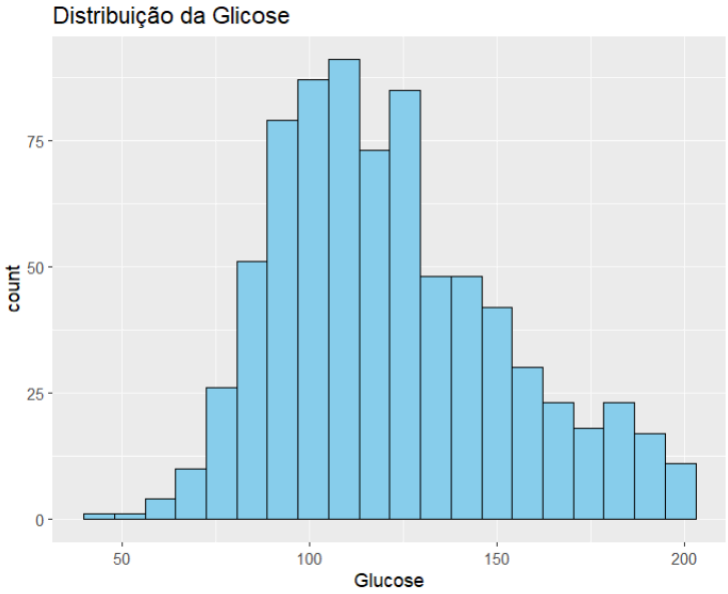

diabetes.

Figura 1: Histograma representando a distribuição de frequência dos níveis de glicose na amostra analisada.

Ao cruzar o Índice de Massa Corporal com os níveis de glicose (Figura 2), observa-se um padrão claro de agrupamento. Os indivíduos diagnosticados com diabetes (pontos vermelhos) tendem a se concentrar no quadrante superior direito do gráfico, indicando que a combinação de IMC elevado e altos níveis de glicose está fortemente associada à presença da doença. Por outro lado, a classe negativa (pontos azuis) predomina em faixas de menor IMC e glicemia. É importante notar que existe uma zona de sobreposição no centro do gráfico, o que justifica a necessidade de modelos multivariados para uma classificação precisa.

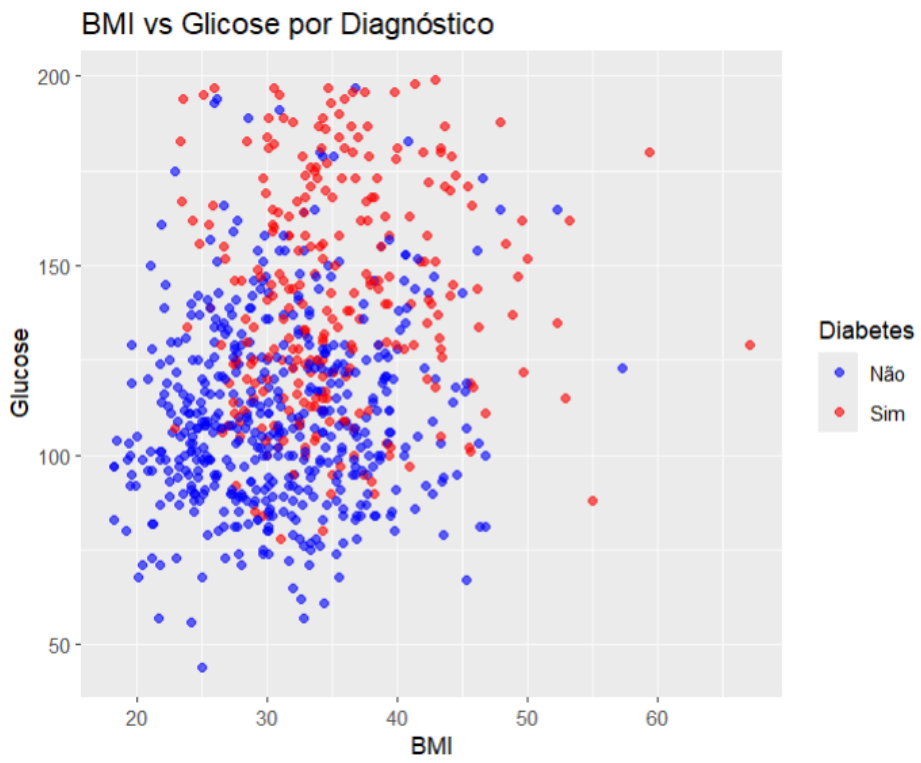

Figura 2: Gráfico de dispersão entre o Índice de Massa Corporal (BMI) e os níveis de Glicose, estratificado pelo diagnóstico de diabetes (Sim/Não).

A matriz de correlação (Figura 3) permite quantificar as relações lineares entre as features. Destacam-se correlações positivas moderadas entre Glucose e Insulin (0.49), o que é fisiologicamente coerente, e entre IMC e Skin Thickness (0.57). A correlação entre Age e Pregnancies (0.54) também reflete o envelhecimento natural associado ao histórico reprodutivo. O valor de 0.24 entre Glicose e BMI corrobora a análise de regressão linear simples, confirmando uma associação positiva, porém fraca/moderada, entre as duas variáveis. A ausência de colinearidade severa (valores acima de 0.8 ou 0.9) entre as variáveis preditoras é um cenário favorável para o treinamento de modelos lineares, como a regressão logística.

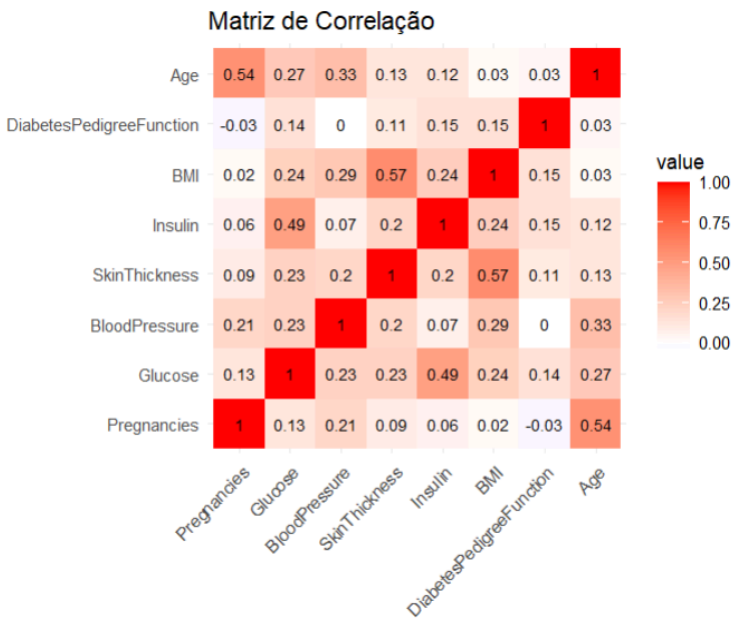

Figura 3: Matriz de correlação de Pearson entre as variáveis preditoras do conjunto de dados. Valores mais próximos de 1 (vermelho escuro) indicam correlação linear positiva mais forte.

A Figura 4 apresenta uma correlação linear positiva e robusta entre o IMC (BMI) e a Espessura da Dobra Cutânea (Skin Thickness). Diferente de outras variáveis do estudo que exibem alta dispersão, este cruzamento revela uma tendência ascendente bem definida e visualmente limpa.

A reta de regressão (em vermelho) confirma que o aumento da massa corporal está diretamente associado à elevação da gordura subcutânea na amostra. A baixa variância em torno da reta indica que o IMC é um preditor confiável para a espessura da pele, fornecendo dados consistentes que auxiliam o modelo de Regressão Logística a atingir a acurácia de 77,27%. Mesmo com a presença de um outlier isolado no topo do gráfico, a tendência central permanece estável e estatisticamente significativa para a caracterização física dos indivíduos.

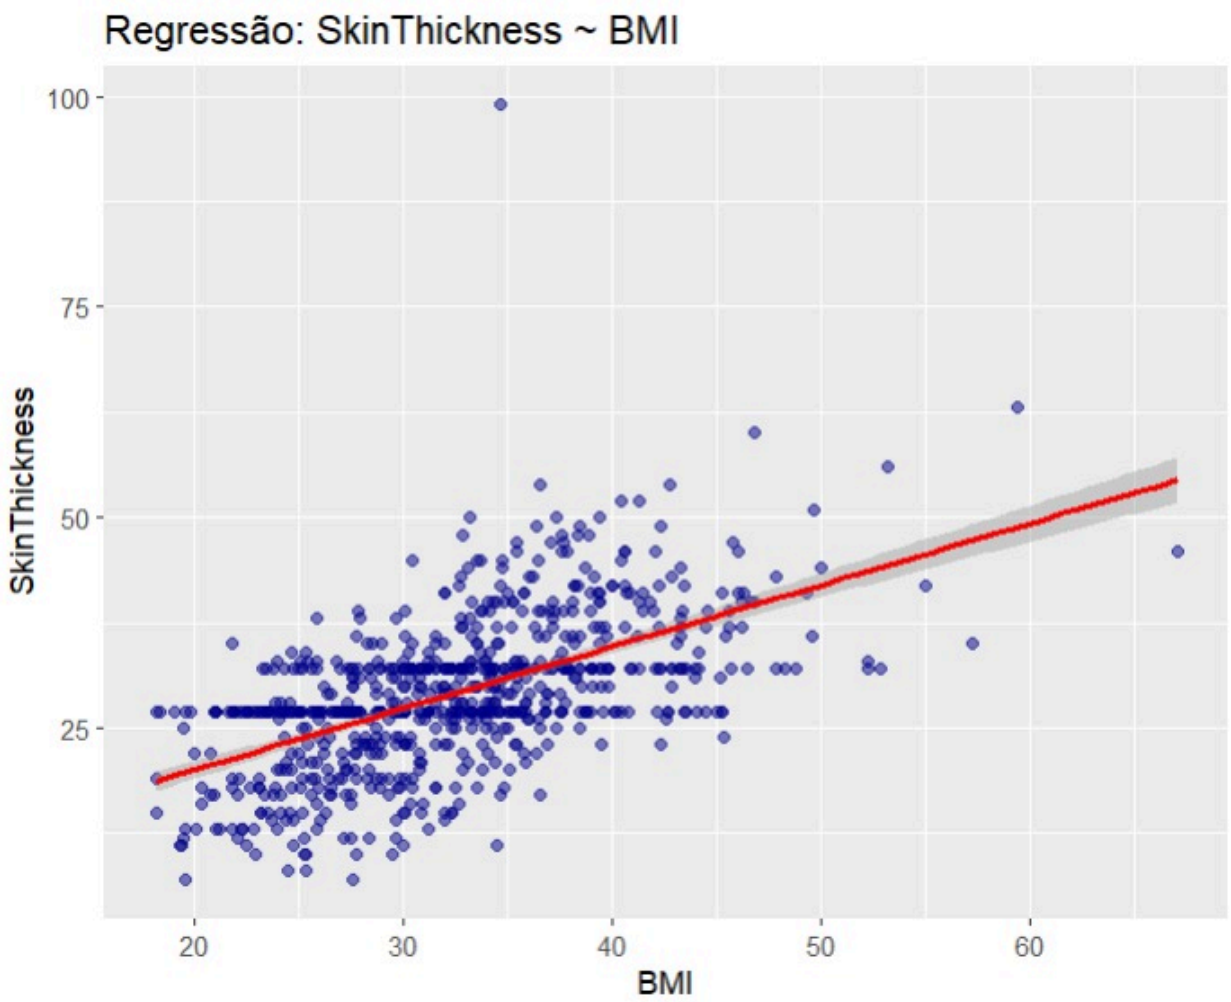

Figura 4: Gráfico de dispersão com ajuste de regressão linear demonstrando a correlação positiva entre o Índice de Massa Corporal (BMI) e a Espessura da Dobra Cutânea (SkinThickness). A linha vermelha representa a tendência central, enquanto a área sombreada indica o intervalo de confiança de 95%.

CONCLUSÕES

As análises estatísticas realizadas permitiram identificar que variáveis metabólicas, especialmente os níveis de glicose e o índice de massa corporal (BMI), apresentam forte associação com o diagnóstico de Diabetes Mellitus.

Os testes de hipóteses evidenciaram dependência significativa entre glicose categorizada e presença da doença, bem como diferenças nas proporções de indivíduos diabéticos entre faixas etárias, indicando maior prevalência em adultos e idosos. Observou-se também diferença na variabilidade da glicose entre os grupos com e sem diagnóstico.

A regressão linear demonstrou relação positiva entre IMC e glicose, indicando que o aumento do índice de massa corporal está associado ao aumento dos níveis glicêmicos.

O modelo de regressão logística apresentou desempenho satisfatório na classificação dos indivíduos, evidenciando que técnicas estatísticas aplicadas no software R são ferramentas eficientes para análise e predição do Diabetes Mellitus.

De modo geral, os resultados confirmam a relevância de fatores clínicos e antropométricos na identificação do risco de diabetes e reforçam a importância da aplicação de métodos estatísticos na tomada de decisão em saúde.

REFERÊNCIAS

AMERICAN DIABETES ASSOCIATION. Standards of Care in Diabetes—2024. Diabetes Care, v. 47, Suppl. 1, 2024. Disponível em: https://diabetesjournals.org/care/issue/47/Supplement_1. Acesso em: 18 mar. 2026.

INTERNATIONAL DIABETES FEDERATION. IDF Diabetes Atlas. 10. ed. Brussels: IDF, 2021. Disponível em: https://diabetesatlas.org. Acesso em: 18 mar. 2026.

SOCIEDADE BRASILEIRA DE DIABETES. Diretrizes da Sociedade Brasileira de Diabetes 2023-2024. São Paulo: SBD, 2023. Disponível em: https://diretriz.diabetes.org.br. Acesso em: 18 mar. 2026.

HOSMER, D. W.; LEMESHOW, S.; STURDIVANT, R. X. Applied Logistic Regression. 3. ed. New York: Wiley, 2013.